

TUGAS 5: FEATURE SELECTION DAN NAIVE BAYES

Deskripsi	Detail
Kelompok	3
Anggota 1	Syarifah Nesia (2024091017) - TEKNIK SIPIL
Anggota 2	Panji Kurnia Akbar (2024081024) - SISTEM INFORMASI
Tanggal	12 Maret 2026
Mata Kuliah	Introduction to AI
Topik Studi Kasus	Deteksi Website Phishing menggunakan Machine Learning
Link Dataset	Phishing Dataset for Machine Learning

Pendahuluan

Keamanan siber menjadi isu krusial di era digital, terutama dengan maraknya serangan *phishing* yang bertujuan mencuri data pribadi melalui situs web palsu yang menyerupai situs resmi. Untuk menghadapi tantangan ini, penggunaan *Machine Learning* menjadi solusi efektif untuk melakukan klasifikasi otomatis terhadap jutaan URL yang beredar. Studi kasus ini menggunakan dataset yang memiliki 50 fitur teknis yang diambil dari struktur URL dan konten halaman web. Melalui teknik *Feature Selection* dan algoritma Naive Bayes, kita bertujuan membangun model yang tidak hanya akurat tetapi juga efisien dalam mendeteksi ancaman secara *real-time*.

Kasus Diskusi

Dalam pengembangan sistem AI deteksi *phishing*, kita memiliki dataset dengan berbagai fitur teknis. Berikut adalah beberapa fitur utama yang tersedia dalam dataset `Phishing_Legitimate_full.csv`:

Nama Fitur	Deskripsi Karakteristik
<code>id</code>	Identitas unik untuk setiap entri dalam dataset.
<code>NumDots</code>	Jumlah titik dalam URL (seringkali banyak pada situs palsu).
<code>UrlLength</code>	Total panjang karakter dari URL yang dianalisis.
<code>InsecureForms</code>	Adanya formulir yang tidak menggunakan protokol keamanan.
<code>FrequentDomainNameMismatch</code>	Ketidaksesuaian nama domain yang sering muncul di halaman.
<code>HttpsInHostname</code>	Pengecekan kata "https" yang disisipkan di dalam <i>hostname</i> .
<code>NumSensitiveWords</code>	Jumlah kata sensitif (seperti: <i>login</i> , <i>verify</i> , <i>bank</i>) dalam URL.

Sistem AI ini akan menggunakan algoritma **Naive Bayes** untuk memprediksi apakah sebuah website masuk kategori **Phishing (1)** atau **Legitimate (0)**.

Pertanyaan Diskusi

1. Menurut Anda, fitur mana yang paling relevan untuk memprediksi kelulusan mahasiswa?

Menurut saya, fitur yang paling relevan adalah **FrequentDomainNameMismatch** dan **InsecureForms**. Secara logis, situs *phishing* sering kali menggunakan nama domain yang mirip namun tidak identik dengan aslinya untuk menipu pengguna. Selain itu, fitur **InsecureForms** sangat krusial karena tujuan utama *phishing* adalah memancing pengguna memasukkan data sensitif pada formulir yang sebenarnya tidak terenkripsi atau dikirim ke server penipu. Data statistik juga menunjukkan fitur-fitur ini memiliki korelasi positif yang sangat kuat terhadap label *phishing*.

2. Fitur mana yang tidak relevan dan sebaiknya dihapus melalui proses feature selection? Jelaskan alasannya

Fitur yang sebaiknya dihapus adalah **id** dan **HttpsInHostname**. Fitur **id** hanyalah urutan administratif yang tidak mengandung informasi karakteristik teknis sebuah serangan; jika dibiarkan, model justru akan belajar dari urutan baris data (*overfitting*). Sementara itu, **HttpsInHostname** dalam dataset ini memiliki nilai yang seragam (nol) pada semua baris, sehingga tidak memberikan daya pembeda sama sekali. Menghapus fitur dengan variansi nol sangat penting dalam *feature selection* agar model tetap sederhana dan efektif.

3. Mengapa pemilihan fitur yang tepat dapat meningkatkan kinerja algoritma Naive Bayes?

Naive Bayes bekerja dengan asumsi bahwa semua fitur bersifat independen dan memberikan kontribusi probabilitas. Jika kita memasukkan fitur yang tidak relevan (seperti **id**), maka perhitungan probabilitas *likelihood* akan terdistorsi oleh informasi yang sebenarnya hanya gangguan (*noise*). Hal ini menyebabkan nilai probabilitas *posterior* yang dihasilkan menjadi kurang akurat. Dengan memilih fitur yang benar-benar berpengaruh, kita memastikan bahwa hasil perkalian probabilitas hanya didasarkan pada sinyal-sinyal kuat serangan *phishing*, sehingga meningkatkan akurasi klasifikasi secara signifikan.

4. Berikan contoh fitur baru (feature engineering) yang dapat dibuat dari data akademik mahasiswa.

Contoh fitur baru yang dapat dibuat adalah **SpecialCharRatio**. Fitur ini dihitung dengan membagi jumlah karakter khusus (seperti @, -, _, %) dengan total **UrlLength**. Secara heuristik, peretas sering menyisipkan banyak karakter khusus untuk menyamarkan URL asli atau untuk melakukan teknik *obfuscation*. Dengan menciptakan rasio ini, kita memberikan informasi yang lebih padat kepada model dibandingkan hanya memberikan jumlah karakter secara terpisah, sehingga model lebih peka terhadap pola URL yang mencurigakan.

Komentar Terhadap Kelompok 4

Keren banget nih pembahasannya soal klasifikasi urgensi rekrutmen di bidang AI. Saya setuju banget sama poin yang di bagian *Feature Selection*, terutama soal penghapusan **job_id**. Emang bener sih, kalau ID itu cuma *noise* yang bisa bikin model Naive Bayes kita malah jadi *overfitting* dan gak akurat pas ngitung probabilitasnya karena dia gak punya nilai prediktif sama sekali.

Yang paling menarik menurut Saya itu ide *Feature Engineering* yang **Salary_to_Exp_Ratio**. Itu ide yang gokil banget buat ngeliat seberapa premium posisi yang dicari perusahaan secara objektif lewat perbandingan gaji dan pengalaman. Bener yang dikatakan, kualitas fitur emang jauh lebih penting daripada sekadar jumlah data yang banyak supaya prediksi model kita bener-benar tajam. Mantap pembahasannya.

Kesimpulan

Sebagai kesimpulan, proses *Feature Selection* adalah tahapan yang tidak boleh dilewatkan dalam *Machine Learning Pipeline*. Melalui studi kasus deteksi *phishing* ini, kita memahami bahwa membuang fitur yang tidak relevan seperti **id** dan fokus pada fitur kunci seperti ketidaksesuaian domain dapat secara langsung meningkatkan akurasi algoritma Naive Bayes. Dengan data yang bersih dan relevan, probabilitas yang dihitung oleh sistem AI menjadi lebih mencerminkan realitas ancaman keamanan, yang pada akhirnya menghasilkan sistem deteksi yang tangguh dan efisien.