

TUGAS 7

Evaluasi dan Pembelajaran Bayesian pada Naive Bayes Classifier

Prediksi Preferensi Belanja Online vs Offline

Kelompok	3
Anggota 1	Syarifah Nesia (2024091017) – Teknik Sipil
Anggota 2	Panji Kurnia Akbar (2024081024) – Sistem Informasi
Mata Kuliah	Introduction to AI

Aktivitas 1: Pemahaman Konsep

1. Perbedaan Training Data dan Testing Data

Training data adalah kumpulan data yang digunakan untuk **melatih model** Naive Bayes. Dalam proses ini, model mempelajari pola-pola yang ada di dalam data — misalnya, seperti apa karakteristik seorang pembeli online dibandingkan pembeli offline. Model menghitung probabilitas setiap fitur terhadap masing-masing kelas target, dan itulah yang disimpan sebagai "pengetahuan" model.

Testing data, sebaliknya, adalah kumpulan data yang **tidak pernah dilihat** model selama proses pelatihan. Testing data digunakan untuk mengukur seberapa baik model mampu memprediksi data baru yang belum dikenalnya. Jika model hanya diuji pada data yang sama dengan training data, kita tidak bisa tahu apakah model benar-benar memahami pola atau sekadar menghafal.

Dalam tugas ini, dataset 25 responden dibagi **70% untuk training (17 data)** dan **30% untuk testing (8 data)**. Model dilatih pada 17 data tersebut, kemudian diuji pada 8 data yang tidak ikut pelatihan.

2. Mengapa Model Harus Dievaluasi?

Evaluasi model diperlukan karena **membangun model saja tidak cukup**. Tanpa evaluasi, kita tidak bisa menjawab pertanyaan mendasar: “apakah model ini benar-benar berguna?”

Ada beberapa alasan utama mengapa evaluasi sangat penting:

1. Memastikan model tidak sekadar menghafal data training (overfitting), melainkan benar-benar memahami pola umum.
2. Mengetahui apakah model layak digunakan untuk prediksi data di dunia nyata.
3. Membandingkan performa beberapa model agar dapat dipilih yang terbaik.
4. Mengidentifikasi kelemahan model sehingga bisa diperbaiki, misalnya dengan menambah data atau mengubah fitur yang digunakan.

Dalam konteks tugas ini, model dievaluasi menggunakan metrik **akurasi, confusion matrix, precision, recall, dan F1-score** untuk mendapatkan gambaran performa yang menyeluruh.

3. Arti Akurasi 80%

Akurasi 80% berarti model memprediksi dengan benar **80 dari setiap 100 data** yang diujikan — atau dalam skala yang lebih kecil, 8 dari 10 prediksi adalah benar. Rumus akurasi adalah:

$$\text{Accuracy} = \text{Jumlah Prediksi Benar} \div \text{Jumlah Seluruh Data}$$

Akurasi 80% menunjukkan model cukup handal, tetapi **belum sempurna**. Masih ada 20% data yang diprediksi salah. Perlu diperhatikan pula bahwa akurasi tinggi tidak selalu mencerminkan model yang baik, terutama jika distribusi kelas tidak seimbang — seperti kasus dalam dataset ini di mana kelas Online Shopper jauh lebih banyak dari Offline Shopper.

Aktivitas 2: Analisis Kasus

Dataset dan Pembagian Data

Dataset yang digunakan adalah hasil survei preferensi belanja dengan **25 responden**. Fitur-fitur yang dipilih untuk klasifikasi adalah: Usia, Frekuensi Belanja Online, Pengaruh Ulasan Pembeli, Kekhawatiran terhadap Risiko Penipuan, dan Pentingnya Interaksi Langsung dengan Penjual. Kelas target adalah preferensi belanja: **Online Shopper** atau **Offline Shopper**.

Distribusi kelas dalam dataset keseluruhan:

Kelas	Jumlah	%
Online Shopper	18	72%
Offline Shopper	7	28%
Total	25	100%

Data dibagi dengan rasio **70:30** (stratified split, random_state=42): 17 data training dan 8 data testing.

Tabel Perbandingan Prediksi vs. Hasil Sebenarnya

Berikut adalah hasil prediksi model Naive Bayes pada 8 data testing:

No	Hasil Sebenarnya	Prediksi Model	Status	Keterangan
1	Online Shopper	Online Shopper	Benar	Prediksi tepat
2	Online Shopper	Online Shopper	Benar	Prediksi tepat
3	Online Shopper	Online Shopper	Benar	Prediksi tepat
4	Online Shopper	Online Shopper	Benar	Prediksi tepat
5	Offline Shopper	Offline Shopper	Benar	Prediksi tepat
6	Offline Shopper	Online Shopper	Salah	Prediksi keliru
7	Online Shopper	Online Shopper	Benar	Prediksi tepat

8	Online Shopper	Online Shopper	Benar	Prediksi tepat
---	----------------	----------------	--------------	----------------

Perhitungan Akurasi

Dari tabel di atas, terdapat **7 prediksi benar** dan **1 prediksi salah** dari total 8 data testing. Maka:

$$\text{Akurasi} = 7 / 8 = 0,875 = 87,5\%$$

Perbandingan akurasi training (**76,47%**) dan testing (**87,50%**) menunjukkan model tidak mengalami overfitting. Justru akurasi testing lebih tinggi, yang menandakan model berhasil melakukan generalisasi dengan baik pada data baru.

Confusion Matrix

Hasil confusion matrix model pada data testing adalah sebagai berikut:

Aktual \ Prediksi	Offline Shopper	Online Shopper
Offline Shopper	1 (TN)	1 (FP)
Online Shopper	0 (FN)	6 (TP)

Metrik Evaluasi Lanjutan

Kelas	Precision	Recall	F1-Score	Support
Offline Shopper	1.00	0.50	0.67	2
Online Shopper	0.86	1.00	0.92	6
Weighted Avg	0.89	0.88	0.86	8

Interpretasi Hasil

Model Naive Bayes mencapai akurasi **87,5%** pada data testing, yang tergolong **cukup baik**. Untuk kelas Online Shopper, model sangat andal: recall 100% berarti semua pembeli online berhasil dikenali tanpa satu pun yang luput. Namun untuk kelas Offline Shopper, recall hanya 50%, artinya satu dari dua responden offline diprediksi secara keliru sebagai online shopper.

Kondisi ini wajar mengingat kelas Offline Shopper memang **kurang terwakili** dalam dataset (hanya 7 dari 25 responden). Model cenderung lebih sering memprediksi kelas mayoritas. Untuk meningkatkan performa pada kelas minoritas, dapat dipertimbangkan teknik seperti penambahan data atau SMOTE.

Aktivitas 3: Refleksi

Apakah Akurasi Saja Cukup untuk Menilai Model?

Tidak. Akurasi saja tidak cukup, terutama ketika data tidak seimbang. Dalam kasus ini, jika model selalu memprediksi **Online Shopper** untuk semua data, akurasinya tetap akan mencapai 72% (18/25) — padahal model tersebut sama sekali tidak berguna karena gagal mendeteksi Offline Shopper.

Ada beberapa situasi di mana akurasi menjadi menyesatkan:

- **Data tidak seimbang (imbalanced class):** seperti kasus ini di mana Online Shopper jauh lebih banyak.
- **Biaya kesalahan berbeda:** misalnya dalam deteksi penyakit, miss (FN) jauh lebih berbahaya daripada false alarm (FP).
- **Tujuan prediksi spesifik:** jika kita ingin memastikan tidak ada Offline Shopper yang terlewat, Recall lebih penting dari Akurasi.

Oleh karena itu, evaluasi yang komprehensif harus mencakup **Precision, Recall, F1-Score, dan Confusion Matrix** seperti yang dilakukan dalam tugas ini.

Dalam Kasus Apa Evaluasi Harus Lebih Teliti?

Evaluasi perlu dilakukan dengan lebih hati-hati dalam beberapa kondisi berikut:

5. **Klasifikasi dengan konsekuensi tinggi** — seperti diagnosis medis, deteksi kecurangan finansial, atau penilaian risiko kredit. Kesalahan prediksi dapat berdampak langsung pada kesehatan atau kerugian material.

6. **Data tidak seimbang** — saat salah satu kelas jauh lebih dominan, akurasi tinggi bisa palsu. Harus digunakan F1-Score atau AUC-ROC sebagai metrik utama.
7. **Dataset kecil** — seperti kasus ini dengan hanya 25 responden. Hasil evaluasi mudah dipengaruhi oleh kebetulan pembagian data. Idealnya digunakan teknik cross-validation.
8. **Gap besar antara akurasi training dan testing** — sebagai indikator overfitting yang berarti model hanya baik pada data yang sudah dikenal, bukan data baru.

Dalam tugas ini, evaluasi dilakukan cukup menyeluruh dengan menggunakan berbagai metrik. Namun mengingat ukuran dataset yang masih kecil (25 data), hasil evaluasi sebaiknya dijadikan **indikasi awal** dan bukan kesimpulan final. Penambahan data survei akan meningkatkan keandalan model secara signifikan.

Kesimpulan

Model Naive Bayes yang dibangun berhasil mengklasifikasikan preferensi belanja responden dengan akurasi **87,5%** pada data testing. Model sangat andal dalam mengidentifikasi Online Shopper (recall 100%), namun masih perlu peningkatan untuk kelas Offline Shopper (recall 50%). Distribusi kelas yang tidak seimbang dalam dataset menjadi faktor utama keterbatasan model saat ini.

Evaluasi yang komprehensif — tidak hanya akurasi, tetapi juga precision, recall, F1-score, dan confusion matrix — memberikan gambaran yang lebih jujur tentang kemampuan model. Untuk pengembangan selanjutnya, penambahan data responden dan penggunaan teknik penyeimbangan kelas dapat meningkatkan performa model secara keseluruhan.