

ANALISIS PREFERENSI PLATFORM BELANJA CONSUMER ONLINE VS. OFFLINE MENGGUNAKAN PENDEKATAN ARTIFICIAL INTELLIGENCE

Disusun untuk Memenuhi Tugas Kuliah

Mata Kuliah : Introduction to AI

Dosen Pengampu:

Riny Nurhajati, S.T., MTI.



Disusun Oleh Kelompok 3:

Syarifah Nesia 2024091017

Panji Kurnia Akbar 2024081024

**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS TEKNOLOGI DAN DESAIN
UNIVERSITAS PEMBANGUNAN JAYA
TANGERANG SELATAN**

2026

DAFTAR ISI

DAFTAR ISI.....	i
BAB I.....	1
1.1 Latar Belakang Masalah	1
1.2 Rumusan Masalah.....	2
1.3 Tujuan Penelitian	2
BAB II.....	3
2.1 Metodologi Pemrosesan Data (AI Pipeline)	3
2.2 Kamus Data Penelitian (Penentuan Variabel)	4
BAB III	6
3.1 Analisis Distribusi Kelas Target (Ketidakseimbangan Data).....	6
3.2 Karakteristik Berdasarkan Kapasitas Ekonomi	7
3.3 Pemetaan Korelasi Atribut Psikologis	8
3.4 Analisis Kritis: Paradoks Risiko Penipuan vs Daya Tarik Harga Murah.....	9
BAB IV	11
4.1 Prapemrosesan Data & Partisi Terstratifikasi	11
4.2 Hasil Rekapitulasi Performa Model.....	12
4.3 Analisis Distribusi Error Prediksi (Confusion Matrix)	13
4.4 Pengujian Batas Diskriminasi Model (Kurva ROC-AUC).....	14
BAB V	15
5.1 Inferensi Faktor Pendorong Berbasis Bobot Log-Odds.....	15
5.2 Aliran Kausalitas Bayesian Network	16
5.3 Analisis Akuntabilitas & Tanggung Jawab Etika AI	17
BAB VI	19
6.1 Kesimpulan Akhir Performa Model.....	19
6.2 Rekomendasi.....	19
DAFTAR PUSTAKA.....	20
LAMPIRAN.....	21

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Perkembangan teknologi informasi dan internet secara masif telah memicu pergeseran perilaku konsumsi masyarakat dari ritel konvensional menuju platform digital. Kompleksitas preferensi belanja konsumen saat ini dipengaruhi oleh variabel multidimensi, mulai dari aspek demografi (**usia dan pekerjaan**), kondisi ekonomi (**kapasitas pengeluaran**), hingga faktor psikologis (**pengaruh review, persepsi harga murah, dan tingkat kekhawatiran penipuan siber**). Sementara platform online unggul dalam aspek efisiensi waktu dan variasi opsi produk, toko fisik (offline) tetap dipertahankan karena memberikan kepastian fisik barang secara langsung serta keunggulan interaksi personal dengan pramu niaga atau SPG.

Guna menangkap pola hubungan non-linear dan interaksi kompleks antar-variabel perilaku tersebut, analisis statistik deskriptif konvensional tidak lagi memadai sehingga diperlukan pendekatan kecerdasan buatan (*Artificial Intelligence*) berbasis *Machine Learning*. Melalui algoritma klasifikasi seperti ***Naive Bayes*, *K-Nearest Neighbors (KNN)*, dan *Logistic Regression***, sistem komputer dapat dilatih menggunakan data historis untuk memprediksi kecenderungan preferensi platform belanja secara otomatis dan presisi. Pendekatan komparatif multimodel ini krusial untuk mengekstrak model terbaik yang tidak hanya memiliki akurasi tinggi, melainkan juga memberikan transparansi melalui koefisien probabilitas (*Log-Odds*) serta pemetaan hubungan sebab-akibat (*Bayesian Network*).

Dalam proyek akhir mata kuliah *Introduction to AI* ini, Kelompok 3 melakukan eksperimen pemodelan menggunakan data primer hasil kuesioner dari **102 responden**. Tantangan teknis utama dalam dataset ini adalah terjadinya *Class Imbalance* (ketidakseimbangan kelas target) yang parah, di mana **84,3% responden merupakan Online Shopper dan hanya 15,7% yang mengidentifikasi diri sebagai Offline Shopper**. Untuk memitigasi risiko bias prediksi terhadap kelas mayoritas, laporan ini membedah implementasi pipa pemrosesan data terstruktur melalui partisi terstratifikasi (*Stratified Split*), evaluasi kurva ROC-AUC, serta penegakan aspek etika AI (*Privacy* dan *Fairness*).

1.2 Rumusan Masalah

Berdasarkan latar belakang masalah yang telah diuraikan, rumusan masalah dalam proyek penelitian ini dirumuskan sebagai berikut:

- Bagaimana pola perilaku konsumen dalam memilih belanja online dan offline berdasarkan aspek usia, pekerjaan, pengeluaran, frekuensi belanja, harga, review, serta tingkat kekhawatiran terhadap penipuan?
- Bagaimana cara mengklasifikasikan preferensi platform belanja konsumen ke dalam kategori *Online Shopper* dan *Offline Shopper* secara akurat berdasarkan data survei primer yang dikumpulkan?
- Algoritma klasifikasi *Machine Learning* manakah yang memberikan performa dan akurasi terbaik dalam memprediksi prioritas preferensi platform belanja konsumen?

1.3 Tujuan Penelitian

Adapun tujuan yang ingin dicapai dari pelaksanaan proyek penelitian ini adalah:

1. Menganalisis pola perilaku konsumen dalam memilih belanja online dan offline berdasarkan faktor demografi, ekonomi, serta variabel psikologis kuesioner.
2. Membangun model klasifikasi *Machine Learning* untuk memprediksi preferensi platform belanja konsumen (*Online* atau *Offline*) berdasarkan ekstraksi data survei.
3. Membandingkan metrik performa beberapa algoritma *Machine Learning* untuk menentukan model klasifikasi terbaik dalam memprediksi preferensi belanja konsumen.

BAB II

PIPELINE PROYEK & PENENTUAN VARIABEL

2.1 Metodologi Pemrosesan Data (AI Pipeline)

Untuk membangun sistem kecerdasan buatan yang andal, transparan, dan terbebas dari risiko bias komputasi, penelitian ini mengimplementasikan pipa pemrosesan data (*AI Pipeline*) yang sistematis. Setiap tahapan dirancang secara kronologis guna memastikan transformasi data mentah dari hasil kuesioner dapat diolah secara optimal oleh algoritma *Machine Learning*.

Alur kerja pipa pemrosesan data AI kelompok kami dirangkum secara kronologis dalam **Tabel 1** berikut:

Tabel 1: Tahapan Kronologis Pemrosesan Sistem AI

No.	Tahapan Proyek AI	Deskripsi Teknis & Implementasi Koding
1	Akuisisi Data Survei	Memuat dataset primer berformat <code>.csv</code> hasil kuesioner dari 102 responden ke dalam <i>DataFrame</i> Pandas murni (<code>df_raw</code>).
2	Seleksi Fitur Perilaku	Menelaah dan menyeleksi 10 atribut kuesioner berskala ordinal dan nominal yang memiliki korelasi logis terhadap perilaku belanja konsumen.
3	Pra-pemrosesan Data	Membersihkan data dari kolom privasi (<code>Nama</code> dan <code>Timestamp</code>), melakukan <i>rename</i> variabel, serta mengonversi data teks nominal menggunakan teknik <i>One-Hot Encoding</i> .
4	Transformasi Target Biner	Mengonversi variabel dependen (<code>Target_Platform</code>) menjadi label digital biner melalui fungsi binerisasi: Online Shopper = 1 dan Offline Shopper = 0.
5	Partisi Data Stratified	Memisahkan dataset menggunakan fungsi <code>train_test_split</code> dengan porsi 80% data latih dan 20% data uji, serta mengunci parameter <code>stratify=y</code> guna memitigasi isu data jomplang.

6	Pelatihan Komparatif Model	Melatih tiga arsitektur model klasifikasi secara paralel pada data latih, yaitu <i>Naive Bayes Classifier</i> , <i>K-Nearest Neighbors</i> (KNN), dan <i>Logistic Regression</i> .
7	Evaluasi Performa Model	Menguji keandalan model pada data uji menggunakan metrik <i>Accuracy</i> , <i>Precision</i> , <i>Recall</i> , <i>F1-Score</i> , visualisasi grafik Kurva ROC-AUC, serta stabilitas uji <i>5-Fold Stratified Cross Validation</i> .
8	Inferensi & Prediksi	Menggunakan arsitektur model terbaik (<i>Logistic Regression</i>) untuk memprediksi data konsumen baru sekaligus mengekstrak pola keputusan melalui bobot koefisien <i>Log-Odds</i> dan <i>Bayesian Network</i> .

2.2 Kamus Data Penelitian (Penentuan Variabel)

Dalam paradigma *Supervised Learning* (pembelajaran terawasi), penentuan peran variabel secara tegas sangat krusial. Penelitian ini menggunakan **13 variabel independen** (fitur masukan X) yang merepresentasikan karakteristik demografi, kapasitas ekonomi, serta indikator psikologis konsumen, serta **1 variabel dependen** (label target y) sebagai muara keputusan klasifikasi sistem AI.

Rincian kamus data beserta skala pengukuran yang digunakan dalam model AI dirangkum pada **Tabel 2** di bawah ini:

Tabel 2: Penentuan Atribut Independen dan Dependen Sistem

Jenis Variabel	Nama Variabel (Koding)	Deskripsi / Keterangan Atribut	Tipe Data & Skala
Independen (X)	Gender	Jenis kelamin riil dari responden survei.	Kategorikal (Nominal)
Independen (X)	Usia	Kelompok usia responden saat mengisi kuesioner.	Kategorikal (Ordinal)
Independen (X)	Pekerjaan	Status atau jenis pekerjaan utama responden.	Kategorikal (Nominal)

Independen (X)	Pengeluaran	Rata-rata kapasitas pengeluaran belanja per bulan.	Kategorikal (Ordinal)
Independen (X)	Freq_Online	Intensitas berbelanja melalui platform online dalam sebulan.	Numerik (Skala Likert 1-5)
Independen (X)	Kategori_Online	Jenis kategori produk yang paling sering dibeli secara online.	Kategorikal (Nominal)
Independen (X)	Alasan_Online Pengaruh_Review	Faktor pendorong utama memilih platform online.	Kategorikal (Nominal)
Independen (X)	Alasan_Offline	Tingkat pengaruh ulasan pembeli sebelum bertransaksi.	Numerik (Skala Likert 1-5)
Independen (X)	Khawatir_Penipuan	Faktor penahan utama untuk tetap memilih toko fisik.	Kategorikal (Nominal)
Independen (X)	Harga_Murah	Tingkat ketakutan terhadap risiko penipuan siber.	Numerik (Skala Likert 1-5)
Independen (X)	Waktu_Tunggu	Persepsi selisih harga online dibandingkan toko fisik.	Numerik (Skala Likert 1-5)
Independen (X)	Waktu_Tunggu	Batas toleransi durasi pengiriman logistik barang.	Kategorikal (Ordinal)
Independen (X)	Penting_SPG	Tingkat kebutuhan pelayanan langsung pramu niaga/SPG.	Numerik (Skala Likert 1-5)
Dependen (y)	Target_Platform	Variabel Target: Prioritas platform belanja (Online/Offline).	Diskrit Biner (0 atau 1)


BAB III

ANALISIS DATA EKSPLORATIF (EDA) & TEMUAN MASALAH

3.1 Analisis Distribusi Kelas Target (Ketidakseimbangan Data)

Tahap awal analisis data eksploratif diarahkan untuk meninjau distribusi respon dari **102 responden** pada variabel dependen (**Target_Platform**). Berdasarkan visualisasi data primer, ditemukan ketimpangan proporsi kelas yang sangat jomplang antara konsumen yang memprioritaskan belanja online dan konsumen yang memilih toko fisik konvensional.

Proporsi Target: Online Shopper vs Offline Shopper



Gambar 1: Persentase Ketidakseimbangan Distribusi Kelas Target Responden (*Online vs. Offline Shopper*)

Analisis Teknis Masalah Komputasi (Class Imbalance):

- **Profil Kelas Aktual:**

Dari total sampel data, kelas mayoritas dikuasai oleh **Online Shopper** dengan persentase mencapai **84,3%** (86 individu), sedangkan kelas minoritas **Offline Shopper** hanya mencakup **15,7%** (16 individu).

- **Risiko Algoritma AI:**


Ketidakseimbangan kelas (*Class Imbalance*) yang parah ini menciptakan tantangan teknis siber yang serius. Model kecerdasan buatan memiliki tendensi bawaan untuk mengalami *overfitting* atau bias prediksi. Algoritma akan cenderung condong menebak kelas mayoritas (**Online**) karena mendapatkan asupan bobot sampel latih yang berlimpah, sementara abai terhadap karakteristik unik kelas minoritas (**Offline**).

- **Solusi Komputasi:**

Sebagai bentuk penegakan keadilan performa algoritma (*Fairness AI*), kelompok kami mengunci parameter `stratify=y` pada tahapan *Train-Test Split* serta menerapkan metode *Stratified Sampling*. Solusi ini menjamin pembagian proporsi kelas antara data latih (81 responden) dan data uji (21 responden) tetap terjaga adil secara matematis.

3.2 Karakteristik Berdasarkan Kapasitas Ekonomi

Faktor daya beli dan kapasitas ekonomi merupakan prediktor krusial dalam memetakan perilaku belanja masyarakat. Penelitian ini mengeksplorasi hubungan linear antara rata-rata kapasitas pengeluaran bulanan responden terhadap platform prioritas mereka.



Gambar 2: [Bar Chart Preferensi Prioritas Platform Belanja Berdasarkan Tingkat Pengeluaran Bulanan](#)

Interpretasi Data Karakteristik Ekonomi:

- **Dominasi Segmen Low-Budget:**


Berdasarkan grafik bar chart di atas, jumlah responden terbanyak didominasi oleh kelompok dengan kapasitas pengeluaran < **Rp1 Juta** per bulan dan disusul oleh kelompok **Rp1 Juta - Rp3 Juta** per bulan. Karakteristik ini mencerminkan profil demografi responden yang mayoritas berada di kategori pelajar atau mahasiswa.

- **Pola Konsumsi Digital:**

Kelompok pengeluaran rendah (< Rp1 Juta) memperlihatkan ketergantungan yang sangat masif terhadap ekosistem digital (**Online Shopper** mencapai lebih dari 40 responden). Hal ini membuktikan bahwa keterbatasan anggaran bulanan mendorong konsumen muda untuk memburu efisiensi harga, program subsidi ongkos kirim, dan promosi agresif yang hanya difasilitasi oleh platform belanja siber.

3.3 Pemetaan Korelasi Atribut Psikologis

Untuk mengukur kekuatan hubungan linear antara seluruh pertanyaan kuesioner berskala ordinal (skala Likert 1-5) terhadap keputusan final konsumen, kelompok kami melakukan perhitungan matriks korelasi linear Pearson.



Gambar 3: [Matriks Heatmap Koefisien Korelasi Linear Atribut Psikologis Terhadap Target Prioritas](#)

Analisis Koefisien Korelasi Terhadap Target (1=Online, 0=Offline):

- **Tuas Penarik Online (Korelasi Positif):**


Variabel **Freq_Online** memiliki nilai korelasi tertinggi terhadap keputusan konsumen sebesar **0,20**, disusul oleh variabel **Harga_Murah** sebesar **0,16**. Nilai positif ini membuktikan bahwa semakin tinggi intensitas kunjungan digital dan semakin kuat persepsi bahwa harga online lebih murah, maka kecenderungan mesin AI memvonis konsumen sebagai *Online Shopper* akan semakin besar.

- **Tuas Penahan Offline (Korelasi Negatif):**

Sebaliknya, variabel **Khawatir_Penipuan** memiliki koefisien korelasi negatif terdalam yaitu -0,31, diikuti oleh variabel **Penting_SPG** sebesar **-0,23**. Tanda negatif ini menyingkap fakta ilmiah bahwa tingginya rasa takut ditipu secara digital dan tingginya ekspektasi terhadap pelayanan langsung di toko fisik bertindak sebagai jangkar penahan yang menarik konsumen untuk tetap setia berbelanja offline.

3.4 Analisis Kritis: Paradoks Risiko Penipuan vs Daya Tarik Harga Murah

Salah satu temuan emas (*gold insight*) dalam riset Kelompok 3 adalah berhasil diungkapnya sebuah fenomena psikologis unik yang disebut sebagai "Paradoks Perilaku Konsumen" melalui teknik tabulasi silang probabilitas (*Crosstab Heatmap*).



Gambar 4: [Crosstab Heatmap Peluang Konversi Online Shopper Berdasarkan Risiko Siber dan Finansial](#)

Interpretasi Fenomena Kritis Solusi Bisnis:

- **Kompromi Keamanan Digital:**

Berdasarkan visualisasi matriks peluang di atas, ditemukan anomali perilaku di mana responden yang mengklaim memiliki tingkat kekhawatiran ditipu sangat tinggi (**Skala 5 pada Y-axis**) ternyata **TETAP memilih belanja online secara mutlak dengan nilai peluang konversi 1,00 (100%)**.

- **Alasan Ilmiah:**

Kondisi ekstrem ini terjadi secara konsisten dengan syarat: konsumen tersebut wajib mempersepsikan bahwa harga barang di toko online jauh lebih murah (**Skala 5 pada X-axis**) dibandingkan toko fisik. Temuan empiris ini membuktikan bahwa daya tarik finansial (diskon besar, promo, gempuran kupon belanja) terbukti secara statistik mampu melumpuhkan rasa takut dan kekhawatiran konsumen terhadap ancaman kejahatan penipuan siber.

BAB IV

DESAIN EKSPERIMEN & EVALUASI MULTIMODEL

4.1 Prapemrosesan Data & Partisi Terstratifikasi

Sebelum dataset dimasukkan ke dalam tahap pelatihan, Kelompok 3 mengeksekusi serangkaian transformasi matematika pada data fitur siap proses (*X_encoded*) agar kompatibel dengan komputasi matriks algoritma *Machine Learning*. Tahap prapemrosesan data lanjutan ini dipecah menjadi tiga alur penting:

1. **Categorical Encoding (One-Hot Encoding):**

Atribut kuesioner yang bertipe teks nominal konvensional dikonversi menjadi matriks biner (0 dan 1) menggunakan fungsi `pd.get_dummies()` dengan parameter `drop_first=True`. Parameter ini sengaja diaktifkan untuk membuang satu kategori kolom turunan pertama guna menghindari jebakan multikolinearitas (kondisi di mana antar-fitur memiliki korelasi linear yang terlalu kuat sehingga merusak interpretasi koefisien model). Melalui proses ini, dimensi data fitur berkembang meluas dari yang semula hanya belasan kolom menjadi total **39 kolom fitur** biner siap latih.

2. **Feature Scaling (StandardScaler):**

Pustaka `StandardScaler` digunakan untuk menyamakan rentang seluruh fitur agar memiliki rata-rata 0 dan varians 1. Langkah ini wajib dilakukan karena algoritma K-Nearest Neighbors (KNN) berbasis jarak (*Euclidean Distance*) sangat sensitif terhadap dominasi nilai angka besar yang dapat memicu eror prediksi.

3. **Pemisahan Data Stratified (Data Segregation):**

Dataset dibagi menggunakan fungsi `train_test_split` dengan rasio 80% data latih (**81 responden**) dan 20% data uji (**21 responden**). Guna mengatasi masalah ketidakseimbangan data pada Gambar 1, parameter `stratify=y` dikunci agar kedua porsi data tersebut tetap mempertahankan proporsi kelas target yang identik (**84,3% Online vs 15,7% Offline**) demi menjaga keobjektifan model.

4.2 Hasil Rekapitulasi Performa Model

Eksperimen komparatif dilakukan secara paralel terhadap tiga arsitektur klasifikasi. Evaluasi stabilitas internal model diuji menggunakan metode **5-Fold Stratified Cross Validation** pada data latih, sedangkan pengujian generalisasi akhir diukur langsung pada data uji.

Tabel 3: Perbandingan Metrik Evaluasi Kinerja Algoritma Klasifikasi

Model Algoritma	CV Mean Accuracy	Test Accuracy	Precision (Online)	Recall (Online)	F1-Score	Status Kelayakan
Naive Bayes	67.9%	42.9%	87.5%	38.9%	53.8%	<i>Underfitting</i>
K-Nearest Neighbors	85.2%	71.4%	87.5%	77.8%	82.4%	<i>Baseline</i>
Logistic Regression	86.5%	81.0%	93.8%	83.3%	88.2%	Model Terbaik

Analisis Perbandingan Ilmiah:

- **Superioritas Logistic Regression:**


Berdasarkan rekapitulasi data di atas, **Logistic Regression keluar sebagai model terbaik**. Model ini mencatatkan nilai stabilitas *CV Mean Accuracy* tertinggi sebesar **86,5%**, diikuti dengan *Test Accuracy* **81,0%** dan *F1-Score* yang sangat kuat yaitu **88,2%**. Hal ini membuktikan bahwa batas fungsi *Sigmoid Bound* yang digunakan Logistic Regression sangat optimal dan stabil dalam memisahkan probabilitas kontinu data kuesioner berskala ordinal tanpa mengalami gejala penumpukan error (*overfitting*).

- **Kegagalan Naive Bayes:**

Algoritma Naive Bayes menempati posisi terendah dengan keandalan data uji yang anjlok ke angka **42,9%**. Penurunan performa yang drastis ini mengindikasikan model mengalami *underfitting*, dipicu oleh asumsi independensi fitur Teorema Bayes yang terlalu kaku, yang mana menganggap seluruh pertanyaan kuesioner berdiri sendiri tanpa adanya hubungan linear terikat.

4.3 Analisis Distribusi Error Prediksi (Confusion Matrix)

Untuk membedah seberapa akurat mesin AI dalam menebak kelas aktual serta memetakan sebaran salah tebak (*error classification*), dilakukan ekstraksi visualisasi peta sebaran *Confusion Matrix*.



Gambar 5: [Perbandingan Confusion Matrix Tebakan Benar-Salah untuk Tiga Algoritma](#)

Analisis Bedah Angka Distribusi Error (Data Uji: 21 Responden):

- **Akurasi Tebakan Benar (True Positives/Negatives):**


Model *Logistic Regression* memperlihatkan akurasi tebakan paling kokoh dengan berhasil menebak secara akurat **15 responden** sebagai *Online Shopper* (*True Positive*) dan **2 responden** sebagai *Offline Shopper* (*True Negative*).

- **Sebaran Meleset (False Positives/Negatives):**

Tingkat kesalahan *Logistic Regression* sangat minim, di mana hanya terdapat 1 kasus *False Positive* (data aktual offline tetapi ditebak online oleh AI) dan 3 kasus *False Negative* (data aktual online tetapi ditebak offline). Angka ini jauh lebih unggul dibandingkan *Naive Bayes* yang meleset parah dengan menghasilkan **11 kasus salah tebak** pada data *Online Shopper* akibat bias asumsi probabilitasnya.

4.4 Pengujian Batas Diskriminasi Model (Kurva ROC-AUC)

Metrik evaluasi terakhir diarahkan untuk menguji ketajaman pembatas keputusan model melalui kurva *Receiver Operating Characteristic* (ROC) dan perhitungan skor *Area Under Curve* (AUC). Semakin kurva melengkung mendekati sudut kiri atas (AUC mendekati angka 1,00), maka model dinilai semakin sempurna.



Gambar 6: [Perbandingan Grafik Kurva ROC dan Skor Area Under Curve \(AUC\)](#)
[Hasil Pengujian](#)

Interpretasi Hasil Grafik ROC-AUC:

- **Logistic Regression (AUC = 0.72):**

Nilai AUC sebesar 0,72 menegaskan kembali posisi *Logistic Regression* sebagai model superior dalam penelitian ini. Secara akademis, skor di atas 0,70 menandakan model memiliki performa diskriminasi yang *acceptable* (baik dan layak) dalam memisahkan probabilitas karakteristik responden belanja online dan offline tanpa terjebak oleh tebakan acak.

- **KNN (AUC = 0.57) & Naive Bayes (AUC = 0.55):**


Kedua model pembanding ini mencatatkan nilai grafik yang sangat memprihatinkan karena posisinya berada dekat dengan garis putus-putus abu-abu (*Tebakan Acak*, $AUC = 0.50$). Skor yang mendekati 0,50 ini mengindikasikan bahwa kemampuan KNN dan Naive Bayes dalam membedakan preferensi platform belanja konsumen hampir setara dengan metode tebakan spekulatif acak koin.

BAB V

EKSTRAKSI PENGETAHUAN & PILAR ETIKA AI

5.1 Inferensi Faktor Pendorong Berbasis Bobot Log-Odds

Keunggulan utama dari pemilihan algoritma *Logistic Regression* sebagai model terbaik tidak hanya terletak pada tingginya angka akurasi data uji, melainkan juga pada aspek transparansi matematisnya (*explainable AI*). Melalui ekstraksi nilai koefisien bobot pembobot (*weights*), model mampu menyingkap seberapa kuat tarikan nilai probabilitas (*Log-Odds*) dari masing-masing atribut kuesioner dalam memengaruhi keputusan konsumen untuk berbelanja secara online maupun offline.



Gambar 7: [Koefisien Matematika Log-Odds Model Terbaik Sebagai Tuas Pendorong dan Penahan Keputusan](#)

Analisis Parameter Bobot Log-Odds:

- Tuas Pendorong Prioritas Online (Koefisien Positif):**


Atribut dengan koefisien positif terbesar didominasi oleh kombinasi **Alasan_Online_Diskon/Promo**, **Kemudahan Akses**, **Malas Keluar Rumah** (mendekati +1.0). Hal ini membuktikan bahwa persepsi harga murah dan kenyamanan logistik menjadi pendorong utama (*driving force*) konsumen menjadi *Online Shopper*. Selain itu, variabel **Gender_Perempuan** juga berkoefisien positif, menunjukkan kecenderungan aktivitas belanja digital yang lebih tinggi pada segmen wanita.

- **Tuas Penahan Prioritas Offline (Koefisien Negatif):**

Sebaliknya, atribut dengan nilai koefisien negatif terdalam ditempati oleh **Khawatir_Penipuan** yang bernilai melampaui -1.0. Indikator psikologis ini menjadi jangkar penahan (*restraining force*) paling kuat yang menghalangi konsumen untuk bertransaksi secara digital. Selain itu, atribut demografi **Usia_<18_Tahun** dan variabel perilaku **Penting_SPG** mengunci koefisien negatif yang signifikan. Hal ini menegaskan bahwa kelompok usia remaja serta konsumen yang memiliki ekspektasi tinggi terhadap pelayanan personal langsung cenderung mempertahankan loyalitas mereka pada ritel fisik (offline).

5.2 Aliran Kausalitas Bayesian Network

Sebagai bentuk pemenuhan materi kompetensi Sesi 14 mengenai penalaran probabilitas berbasis kondisi makro, penelitian Kelompok 3 mengonstruksikan alur hubungan sebab-akibat ke dalam arsitektur jaringan graf berarah yang disebut **Directed Acyclic Graph (DAG)**.



Gambar 8: [Arsitektur Directed Acyclic Graph \(DAG\) Aliran Probabilitas Bersyarat Pengaruh Sebab-Akibat](#)

Interpretasi Aliran Kausalitas Graf:

- **Akumulasi Bersyarat (*Conditional Probability*):**

Representasi arsitektur jaringan graf berarah di atas membuktikan secara ilmiah bahwa variabel target akhir, yaitu simpul **BelanjaOnline**, bukan merupakan sebuah keputusan tunggal yang berdiri sendiri. Keputusan tersebut merupakan muara akhir dari akumulasi kausalitas probabilitas bersyarat.

- **Dinamika Simpul Hulu ke Hilir:**

Lima simpul akar utama di tingkat hulu—yakni **ReviewPositif**, **RisikoRendah**, **HargaMurah**, **FrekuensiTinggi**, dan **AdaPromo**—secara simultan mengalirkan arah panah pengaruh menuju simpul hilir. Setiap peningkatan probabilitas positif pada simpul-simpul hulu ini akan secara otomatis mendongkrak nilai peluang konversi target klasifikasi pada simpul tujuan secara terukur dan presisi.

5.3 Analisis Akuntabilitas & Tanggung Jawab Etika AI

Sesuai dengan standar profesional tata kelola kecerdasan buatan (*AI Governance*) pada materi Sesi 15, implementasi *Machine Learning* wajib diuji dampak sosialnya guna menjamin keandalan sistem penunjang keputusan yang bertanggung jawab. Kelompok kami melakukan evaluasi etika penggunaan AI melalui enam parameter pilar berikut:

1. **Penegakan Pilar Privasi (*Privacy Ethics*):**

Kebijakan perlindungan data diimplementasikan secara ketat sejak awal pipa pemrosesan data (*data ingestion*). Seluruh fitur identitas personal responden yang bersifat *noise*, seperti variabel Nama Lengkap dan Timestamp, dihapus secara permanen dari basis data komputasi. Langkah ini menjamin hak anonimitas para responden survei terpenuhi seutuhnya.

2. **Penegakan Pilar Keadilan (*Fairness AI*):**

Untuk memitigasi bias algoritma akibat isu ketimpangan distribusi kelas target yang jomplang (**84,3% Online vs 15,7% Offline**), model kami menolak pembagian data acak konvensional. Kelompok kami menerapkan skema pemisahan data terstratifikasi (*Stratified Split*) dan validasi silang *Stratified K-Fold* guna memastikan performa prediksi mesin AI tetap adil bagi kelompok minoritas.

3. **Analisis Pihak yang Diuntungkan (*Beneficiaries*):**

Pihak yang mendapatkan keuntungan terbesar dari implementasi sistem AI ini adalah manajer pemasaran digital dan pemilik platform *e-commerce*. Nilai koefisien bobot *Log-Odds* dapat dimanfaatkan sebagai basis data pendukung keputusan untuk merancang kampanye iklan yang tepat sasaran, sehingga menghemat biaya operasional pemasaran.

4. **Analisis Pihak yang Dirugikan (*Disadvantaged Parties*):**

Pihak yang berpotensi menghadapi dampak negatif adalah pelaku usaha toko retail fisik konvensional skala kecil (UMKM offline) jika mereka lambat beradaptasi. Hasil ekstraksi pengetahuan AI membuktikan bahwa dominasi persepsi harga murah digital sangat kuat mencengkeram pikiran mayoritas responden konsumen muda saat ini.

5. **Garis Batas Akuntabilitas (*Accountability Boundary*):**

Model klasifikasi ini murni bertindak sebagai Sistem Pendukung Keputusan (*Decision Support System*). Apabila terjadi kegagalan atau kerugian finansial akibat implementasi strategi bisnis di lapangan, tanggung jawab hukum dan moral akhir mutlak berada di tangan analis manusia (manajer operasional), bukan pada kode algoritma komputer.

6. **Mekanisme Koreksi Kesalahan Sistem:**

Mengingat model *Logistic Regression* memetakan nilai keluaran berupa probabilitas kontinu (rentang angka 0.00 hingga 1.00) sebelum dikonversi ke kelas biner, analis manusia memiliki kemampuan untuk mengoreksi bias pasar nyata secara dinamis. Ambang batas tebakan standar (*default decision threshold bound*) sebesar 0,50 dapat diubah atau digeser (misalnya dinaikkan ke angka 0,65) untuk disesuaikan dengan fluktuasi anomali pasar nyata di lapangan.

BAB VI

KESIMPULAN DAN REKOMENDASI

6.1 Kesimpulan Akhir Performa Model

1. **Pola Perilaku Konsumen:**

Keputusan platform belanja dipengaruhi kuat oleh faktor psikologis dan ekonomi. Terjadi paradoks di mana kekhawatiran penipuan siber berhasil dimitigasi secara mutlak oleh persepsi harga online yang jauh lebih murah.

2. **Efektivitas AI Pipeline:**

Implementasi *One-Hot Encoding*, *Feature Scaling* (StandardScaler), dan parameter *Stratified Split* sukses mengatasi masalah ketidakseimbangan kelas (*Class Imbalance* 84,3% vs 15,7%) secara objektif dan adil (*Fairness*).

3. **Algoritma Terbaik:**

Logistic Regression merupakan model terbaik dengan capaian *Test Accuracy* 81,0% dan *F1-Score* 88,2%, terbukti jauh lebih unggul dan stabil dibandingkan *Naive Bayes* dan *K-Nearest Neighbors* (KNN).

6.2 Rekomendasi

1. **Ritel Digital (*E-commerce*):**

Meningkatkan sistem jaminan keamanan transaksi dan transparansi ulasan produk (*review* pembeli) untuk mereduksi rasa takut konsumen terhadap risiko penipuan digital.

2. **Ritel Fisik (*Toko Offline*):**

Mengoptimalkan kualitas pelayanan langsung pramu niaga/SPG serta menonjolkan keuntungan mencoba fisik barang secara instan tanpa adanya waktu tunggu pengiriman.


3. **Pengembangan AI Masa Depan:**

Memperluas volume dataset kuesioner dan mengeksplorasi arsitektur algoritma tingkat lanjut berbasis *Ensemble Learning* (seperti *Random Forest* atau *XGBoost*) agar lebih adaptif terhadap perubahan tren pasar.


DAFTAR PUSTAKA

- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16(1), 321–357.
- Chiu, C. M., Wang, E. T., Fang, Y. H., & Huang, H. Y. (2014). Understanding Customers' Repeat Purchase Intentions in B2C E-Commerce: The Roles of Utilitarian Value, Hedonic Value and Perceived Risk. *Information & Management*, 51(7), 855–876.
- Cover, T., & Hart, P. (1967). Nearest Neighbor Pattern Classification. *IEEE Transactions on Information Theory*, 13(1), 21–27.
- Degeratu, A. M., Rangaswamy, A., & Wu, J. (2000). Consumer Choice Behavior in Online and Traditional Supermarkets: The Effects of Brand Name, Price, and Other Search Attributes. *International Journal of Research in Marketing*, 17(1), 55–78.
- Heckerman, D. (1997). Bayesian Networks for Data Mining. *Data Mining and Knowledge Discovery*, 1(1), 79–119.
- Katawetawarak, C., & Wang, C. L. (2011). Online Shopper Behavior: Influences of Online Shopping Decision. *Asian Journal of Business Research*, 1(2), 66–74.
- Kotsiantis, S. B., Zaharakis, I., & Pintelas, P. (2007). Supervised Machine Learning: A Review of Classification Techniques. *Informatica*, 31(3), 249–268.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12(10), 2825–2830.
- Peng, C. Y. J., Lee, K. L., & Ingersoll, G. M. (2002). An Introduction to Logistic Regression Analysis and Reporting. *The Journal of Educational Research*, 96(1), 3–14.
- Rish, I. (2001). An Empirical Study of the Naive Bayes Classifier. *IJCAI Workshop on Empirical Methods in Artificial Intelligence*, 3(22), 41–46.

LAMPIRAN



Gambar 9: Antarmuka Grafis premium *Executive Dashboard* pada Sistem Nexus AI Analytics



Gambar 10: Antarmuka Modul *AI Persona Predictor* (Predictive Intelligence Simulator) Berbasis *Logistic Regression*